

CC3092 — Laboratorio 6: Transfer Learning y Fine-Tuning

CIFAR-10 · CNN desde cero · VGG-16 feature extractor · VGG-16 fine-tuning (112×112)

Hardware de entrenamiento: NVIDIA Tesla T4 (CUDA) — entorno de entrenamiento. Semilla 42.

1. Investigación: transfer learning en PyTorch

vgg16 / VGG16_Weights cargan la arquitectura y pesos ImageNet; **weights.transforms()** define el preprocesado oficial (224×224). **features / avgpool / classifier** separan backbone, pooling adaptativo y cabeza MLP. **requires_grad** congela o descongela bloques. **train/eval** y **no_grad** controlan Dropout/BN e inferencia. **param_groups** permiten LR distinto en backbone y clasificador. **fvcore** estima FLOPs; **max_memory_allocated / synchronize** miden memoria y tiempo en GPU. Un MAC $\approx$ 2 FLOPs. Parámetros entrenables $\subseteq$ totales.



Se usa **112×112** (no 224) por cómputo: $\approx 12.25 \times$ píxeles vs 32×32 (224 sería $49 \times$), misma resolución en FE y FT.

2. Resultados de las 9 iteraciones (validación)

experiment	unfrozen_blocks	best_epoch	best_val_f1	best_val_accuracy	trainable_params	total_training_time_s
CNN-A	-	8	0.7436	0.7463	323498	126
CNN-C	-	8	0.7178	0.7276	323498	138
CNN-B	-	8	0.7049	0.7115	323498	129
VGG-FE-B	none	6	0.7792	0.7869	119586826	340
VGG-FE-A	none	6	0.7646	0.7718	119586826	327
VGG-FE-C	none	6	0.7594	0.7624	119586826	325
VGG-FT-B	4+5	7	0.8489	0.8512	132566026	610
VGG-FT-A	5	7	0.8254	0.8356	126666250	582
VGG-FT-C	5	7	0.8242	0.8270	126666250	593

3. Comparación de rendimiento y recursos (mejores modelos)

family	test_f1	test_accuracy	f1_10pct	total_params	trainable_params	flops_per_image	latency_ms	peak_gpu_memory_mb
CNN	0.7325	0.7320	0.6191	323,498	323,498	0.039G	0.35	845
VGG-FE	0.7756	0.7750	0.7029	134,301,514	119,586,826	3.956G	4.85	2115
VGG-FT	0.8423	0.8420	0.7943	134,301,514	132,566,026	3.956G	5.12	3560



4. Análisis y conclusiones

El mejor desempeño en test es **VGG-FT** ($F1=0.8423$, $acc=0.8420$). La CNN alcanza $F1=0.7325$ con mucho menos cómputo (38.9 MFLOPs/imagen). FE (0.7756) mejora a la CNN entrenando solo el clasificador; FT aporta +0.0667 F1 descongelando bloques superiores con LR bajo en el backbone, sin indicios claros de catastrophic forgetting.

Con el 10 % de datos, la CNN es la más afectada; FE/FT degradan menos gracias a ImageNet. Los errores recurrentes (cat↔dog, auto↔truck, bird↔airplane) aparecen en los tres modelos. Despliegue: GPU→VGG-FT; móvil→CNN o MobileNetV3/EfficientNet-B0.

Repositorio: ver notebook **Laboratorio6_Transfer_Learning.ipynb** y carpeta **outputs_lab6/**.